

A2C ,REINFORCE ותרגיל מספר 3

L07 - REINFORCE, A2C and Exercise 3

ד"ר יורם סגל

כל הזכויות שמורות - © ד"ר יורם סגל

May 2026

סיכום שיעור - למידת חיזוק

תוכן העניינים

6	1	הקדמה: מה אנחנו מחפשים בלמידת חיזוק (Policy vs. Prediction)
6	1.1	מהי מדיניות: וקטור של הסתברויות
7	1.2	דיוק והעמקה: הגדרה פורמלית של המדיניות ופונקציית המטרה
7	1.3	המצב כווקטור מספרים: דוגמת העגלה והעמוד
8	1.4	מקומי מול מצטבר: ההבדל המהותי
9	2	אלגוריתם REINFORCE: גרדיאנט המדיניות
9	2.1	תהליך האימון: מהגרלה אקראית ועד תיקון
9	2.2	מתי נגמרת אפיזודה
9	2.3	קרדיט משותף
10	2.4	הנוסחה: למה גרדיאנט ולמה לוג
11	2.5	דיוק והעמקה: טריק נגזרת הלוג (Log-Derivative Trick)
12	2.6	הקשר ל-Cross Entropy: One-Hot כ"אמת"
12	2.7	דיוק והעמקה: שקילות מתמטית ל-Cross Entropy
13	3	בעיית הרעש וקו הבסיס (Baseline)
13	3.1	הדגמה: צעד אחד שמקלקל את הכול
13	3.2	הפתרון: החסרת הממוצע
14	3.3	הממוצע של מה?
14	3.4	דיוק והעמקה: מדוע קו הבסיס אינו מטה את האומדן
15	4	תגמול מהמצב והלאה (Reward-to-Go), עיקרון הסיבתיות וחוקי מרקוב
15	4.1	מרקוב: לא מעניין מאיפה הגעתי
15	4.2	סכימה הדרגתית
15	4.3	דיוק והעמקה: סיבתיות מול מרקוביות
17	5	שחקן ומבקר: ארכיטקטורת Actor-Critic (A2C)
17	5.1	משל השחקן והמאמן

17	שתי רשתות, שני מוצאים	5.2
17	היתרון (Advantage): הפרש בין תחזית למציאות	5.3
18	דיוק והעמקה: הגדרת היתרון וקירוב ה-TD	5.4
19	שני עדכונים: האקטור והקריטיק	5.5
20	דיוק והעמקה: על השם A2C	5.6
21	סיכום: שלושת מנגנוני השיפור	6
21	REINFORCE מול A2C: ההבדל	6.1
22	טבלה מסכמת: מילון המונחים המתמטיים	6.2
23	טבלה מסכמת: מפת מקורות לקריאת המשך	6.3
24	תרגיל מספר 3: LSTM, REINFORCE ו-A2C - להמלצת אימונים	7
24	חלק A – ניסוח הבעיה	7.1
25	1.7.1 הרכיבים שעליכם להגדיר	
25	2.7.1 תוצרי חלק A	
25	חלק B – מסד הנתונים להורדה	7.2
26	1.7.2 מדוע מסד הנתונים הזה מתאים	
26	2.7.2 הוראות הורדה ישירה	
26	3.7.2 תוכן הקבצים	
27	4.7.2 בניית מתאמן סינתטי אחד	
27	חלק C – מימוש מודל LSTM	7.3
28	1.7.3 המימוש הנדרש	
28	2.7.3 הקשר תיאורטי: מודל עולם (World Model)	
29	חלק D – מימוש REINFORCE מעל מודל ה-LSTM	7.4
29	1.7.4 ניסוח המדיניות	
29	2.7.4 עיצוב התגמול	
29	3.7.4 עדכון REINFORCE	
30	חלק E – מימוש A2C מעל מודל ה-LSTM	7.5
30	1.7.5 מבנה המודל	
30	חלק F – ניתוח ודיון	7.6

31	נקודות לדין ותוצרים	1.7.6
31	רשימת הגשה	7.7
33	מקורות וביבליוגרפיה (References)	8

מילות מפתח (Keywords)

שם השיעור: L07 – A2C, REINFORCE ותרגיל מספר 3.

מילות מפתח:

- מדיניות (Policy) וגרדיאנט המדיניות (Policy Gradient).
 - אלגוריתם REINFORCE ולמידה מבוססת אפיזודות.
 - תשואה מצטברת (Return) ותוחלת התגמול.
 - קו בסיס (Baseline) והפחתת שונות (Variance).
 - תגמול מהמצב והלאה (Reward-to-Go) וחוקי מרקוב.
 - יתרון (Advantage) ושגיאת הפרש זמני (TD Error).
 - שחקן-מבקר (Actor-Critic, A2C) ופונקציית ערך (Value Function) $V(s)$.
 - טריק נגזרת הלוג (Log-Derivative Trick) ומשפט גרדיאנט המדיניות.
 - משתנה בקרה (Control Variate) ועיקרון הסיבתיות (Causality).
 - משוואת בלמן (Bellman Equation) ושקילות ל-Cross Entropy.
 - רשתות זיכרון: RNN, LSTM, Transformer; תצפית חלקית (POMDP).
 - מודל עולם (World Model) ומיסוך פעולות (Action Masking).
- מראה: ד"ר יורם סגל. כל הזכויות שמורות לד"ר יורם סגל ©.

1 הקדמה: מה אנחנו מחפשים בלמידת חיזוק (Policy vs. Prediction)

בואו ננסח רגע את הבעיה בצורה עקרונית. בלמידת חיזוק (Reinforcement Learning) אנחנו לא מחפשים רק תחזית או סיווג, כמו שאנחנו רגילים בלמידה עמוקה רגילה. אנחנו מחפשים **מדיניות** – Policy – כלומר כלל החלטה שמקבל את המצב ומחזיר את הפעולה. ובאופן כללי יותר, ההתפלגות של הפעולות האפשריות, וקטור של הסתברויות לאן לפנות.

המשמעות היא שהמערכת שלנו צריכה ללמוד **איך להתנהג לאורך זמן**, ולא רק איך להגיב באופן מיידי. זה הבדל מהותי. לכן פונקציית המטרה שלנו לא תלויה רק בצעד אחד, אלא בתשואה מצטברת לאורך מסלול שלם.

חשוב להבין כבר עכשיו שהאלגוריתמים שנלמד – REINFORCE ו-Actor-Critic – אינם רק כלי משחק עבור רובוטים וירטואליים. הם מנגנונים כלליים ורבי-עוצמה לפתרון בעיות של **קבלת החלטות סדרתית תחת אי-ודאות**, והם עומדים כיום בלב יישומים מרכזיים במדעי המחשב: בקרת רובוטים ומערכות אוטונומיות, שחקני-על במשחקים, מערכות המלצה אדפטיביות, ואפילו כיוונון מודלי שפה גדולים בשיטת RLHF (Reinforcement Learning from Human Feedback). המשותף לכולם: אין "תשובה נכונה" יחידה לכל צעד – יש רצף החלטות שמטרתו למקסם תוצאה מצטברת לאורך זמן [1].

1.1 מהי מדיניות: וקטור של הסתברויות

נניח שהגעתי לאיזשהו צומת ואני צריך לקבל החלטה: ימינה או שמאלה. בקיצור, מה הפעולה (Action) שאני צריך לעשות במצב (State) שבו אני נמצא. כשאנחנו כותבים $\pi_\theta(a | s)$, הכוונה היא להסתברות. הדבר הזה מתאר וקטור של הסתברויות. לדוגמה, במצב מסוים הרשת יכולה להגיד לי: "עדיף לפעול בהסתברות של 30% שמאלה ובהסתברות של 70% ימינה".

הפרמטרים של המדיניות מסומנים ב- θ . במקום לשמור ערך לכל פעולה בטבלה (כמו שעשינו ב-Q-Learning), כאן אנחנו לומדים התפלגות הסתברויות. זו המדיניות שלנו, וזה וקטור ההסתברויות.

1.2 דיוק והעמקה: הגדרה פורמלית של המדיניות ופונקציית המטרה

הצגנו את המדיניות באופן אינטואיטיבי כווקטור הסתברויות; כעת ננסח אותה במדויק. המדיניות הסטוכסטית מסומנת $\pi_\theta(a | s) = \mathbb{P}(A_t = a | S_t = s; \theta)$ — ההסתברות לבחור פעולה a בהינתן המצב s ופרמטרי הרשת θ . מטרת הלמידה היא למצוא את הפרמטרים θ הממקסמים את פונקציית המטרה $J(\theta)$, המוגדרת כתוחלת התשואה המצטברת לאורך המסלול כולו:

$$(1) \quad J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^T \gamma^t r_t \right]$$

כאשר $\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \dots)$ הוא המסלול (Trajectory), r_t התגמול המיידי בזמן t , ו- $\gamma \in [0, 1]$ הוא מקדם ההיוון (Discount Rate), המגדיר את ערך הזמן של תגמולים עתידיים. כל מה שנפתח בהמשך — גרדיאנט המדיניות, קו הבסיס והיתרון — הוא בסופו של דבר דרך לחשב או לקרב את הגרדיאנט $\nabla_\theta J(\theta)$ [1].

1.3 המצב כווקטור מספרים: דוגמת העגלה והעמוד

איך נראה המצב בפועל? המצב הוא וקטור של מספרים שמתאר את העולם. ניקח דוגמה קלאסית: יש לי עגלה (Cart) שיכולה לנסוע קדימה או אחורה, ועליה עומד עמוד בנפילה חופשית. אני לא רוצה שהעמוד ייפול. את המצב אני יכול לתאר בעזרת ארבעה ערכים:

- מיקום העגלה על המסילה.
 - הזווית של העמוד ביחס לאנך. ככל שהזווית גדולה יותר, כך הסיכון שניפול גדל.
 - המהירות של העגלה.
 - המהירות הזוויתית של העמוד — כלומר הנגזרת, כמה הזווית משתנה.
- את הווקטור הזה אני מכניס לרשת נוירונים, ובמוצא הרשת אני מקבל את וקטור ההסתברויות לפעולות: אקשן אחד, אקשן שתיים, אקשן שלוש, וכן הלאה — לכל פעולה הסתברות משלה. כמוכך, המצב יכול להיות מתואר ביותר מארבעה ערכים, תלוי כמה מורכב העולם שלנו.

1.4 מקומי מול מצטבר: ההבדל המהותי

חשוב מאוד להבחין בין שני דברים שונים לגמרי. דמיינו שהמטרה שלי היא להגיע בעוד חודש למשקל גוף מסוים. אם עכשיו אני ארים משקולות וארוץ מהר, יכול להיות שהורדתי כמה קלוריות – אבל לא בטוח שזה עוזר לי למטרה הסופית. אולי השרירים שלי יתכווצו, אולי מחר כבר לא אוכל להתאמן בכלל. זאת אומרת, יש הבדל בין מה שאני עושה **עכשיו או מחר בבוקר**, לבין **סדרת הפעולות** שאני צריך לבצע כדי להגיע ליעד. כל מה שאני מראה לכם בשיעור הזה עוסק ביעד – בתשואה המצטברת לאורך כל המסלול.

לעומת זאת, רשתות עם זיכרון – RNN עם זיכרון קצר, LSTM עם זיכרון ארוך יותר, ו-Transformer עם מנגנון ה-Attention שרואה למרחקים גדולים – משמשות, **כשהן עומדות בפני עצמן**, בעיקר כמודלים **חזאיים**: הן עונות על שאלה מקומית – “בהינתן ההיסטוריה, מה הצעד הבא הסביר?” – ואינן פותרות ישירות את בעיית האופטימיזציה של מדיניות מצטברת. בהמשך נראה איך אנחנו משלבים את היכולת החזאית המקומית הזו עם המבט המצטבר של למידת חיזוק.

דיוק חשוב: אין להבין מכך שרשתות זיכרון הן “מקומיות” במובן הצר. נהפוך הוא – בלמידת חיזוק אנו מנצלים אותן דווקא כדי **להתגבר על מגבלות חוק מרקוב** כאשר הסביבה נצפית באופן חלקי בלבד, מצב המכונה POMDP (Partially Observable MDP) [2]. במצב כזה תצפית בודדת אינה מהווה “מצב מרקובי” מלא, והרשת ממירה **רצף תצפיות היסטוריות** לייצוג מצב חבוי h_t המקרב את המציאות השלמה – ייצוג שעליו אפשר להפעיל מדיניות עקבית. תפיסה זו עומדת בבסיס “מודלי עולם” (World Models), שאליהם נחזור בתרגיל המעשי בפרק 7.

2 אלגוריתם REINFORCE: גרדיאנט המדיניות

REINFORCE הוצג במקור בשנת 1992 על ידי רונלד ג'יי. וויליאמס, כמשפחת שיטות מבוססות-גרדיאנט לאימון יחידות סטוכסטיות, והוא מהווה את עמוד התווך של שיטות גרדיאנט המדיניות (Policy Gradient) [3], [4]. זהו אלגוריתם קלאסי ובסיסי ביותר להבנת המדיניות. כל מה שהוא יודע לייצר זה וקטור של הסתברויות לאיזו פעולה לבצע. הוא משתמש ברשת אחת בלבד – בדרך כלל רשת Fully Connected פשוטה מאוד, עם שכבה אחת של כ-128 נוירונים. מאד פשוט.

2.1 תהליך האימון: מהגרלה אקראית ועד תיקון

הרעיון של האלגוריתם הוא שאני מתחיל עם רשת אקראית לחלוטין – רעש אקראי, שום דבר לא ידוע. אני לוקח מצב התחלתי, מזין אותו לרשת, ומקבל וקטור של הסתברויות. עכשיו אני מגריל פעולה לפי המשקל של ההסתברויות: אם לימין יש 70% ולשמאל 30%, רוב הסיכויים שאבחר ימין, אבל לא תמיד. ואז אני ממשיך: מבצע את הפעולה, מגיע למצב חדש, מגריל שוב, וכן הלאה עד סוף האפיזודה (Episode).

2.2 מתי נגמרת אפיזודה

האפיזודה יכולה להיגמר מאחת משלוש סיבות:

1. הגעתי לפרס – כלומר הצלחתי במשימה.
 2. נכשלתי – למשל הרובוט נפל מהשולחן.
 3. נגמרו המצבים – הגבלתי מראש את כמות הצעדים המותרת.
- בתוך האפיזודה, בכל מצב החלטתי משהו: פה שמאלה, פה ימינה, וכן הלאה. הייתי במצב s_0 ובחרתי a_0 , הייתי ב- s_1 ובחרתי a_1 , וכן הלאה.

2.3 קרדיט משותף

בסוף האפיזודה קיבלתי ניקוד מצטבר. נניח שפה הרווחתי נקודה, פה הפסדתי שתיים, פה הרווחתי עשר – ובסך הכול קיבלתי 100 נקודות. עכשיו, מה אני עושה? אני חוזר אחורה ואומר: כל הפעולות שתרמו למסלול הזה היו טובות, אז בואו נגדיל את ההסתברות שלהן.

עכשיו, יכול להיות שדווקא הפנייה שמאלה במצב מסוים לא באמת תרמה ל-100 הנקודות. זה לא משנה! חשבו על חברה שמחלקת בונוסים: לא בטוח שכולם תרמו אותו דבר, אבל היא מחלקת לכולם כי **בסך הכול החברה הצליחה**. אני לא נכנס לרזולוציה הקטנה. עובדתית, המסלול הזה הביא 100 נקודות, אז בואו נשפר את כל מי שהשתתף בו.

2.4 הנוסחה: למה גרדיאנט ולמה לוג

מה שכתוב בנוסחה הוא שאת ההסתברות לבצע פעולה במצב t אני מחשב, ולוקח את הלוג שלה. למה לוג? כי במתמטיקה לקיחת לוג של ההסתברויות הופכת כפל לחיבור, והמספרים נשארים "נורמליים" – אחרת הם יכולים להיות קטנים מאוד. זהו יתרון מעשי וחשוב במימוש המספרי; את הסיבה התיאורטית העמוקה יותר נראה בסעיף הבא. הנוסחה לעדכון הפרמטרים היא:

$$(2) \quad \theta \leftarrow \theta + \alpha \sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t$$

כאשר G_t היא התשואה המצטברת (Return) – כל הכסף שהסוכן אסף מההתחלה ועד הסוף, ו- α הוא קצב הלמידה.

למה זה נקרא **גרדיאנט**? כי אני משנה את ההסתברות של כל פעולה רק בכיוון שלה. מי שתרים מקבל את ה"צ'ופר", ומי שלא תרים לא מקבל. אני לוקח את ההסתברויות של הפעולות שהשתתפו ומכפיל אותן ב- G_t , וכך כל פעולה לוקחת חלק יחסי מהתשואה לפי ההסתברות שלה.

2.5 דיוק והעמקה: טריק נגזרת הלוג (Log-Derivative Trick)

ההסבר שלמעלה – שהלוג הופך כפל לחיבור ומונע קריסה נומרית של מספרים קטנים מאוד – נכון ושימושי במימוש, אך זהו **היתרון המעשי** בלבד, ולא הסיבה התיאורטית להופעת הלוג במשוואת העדכון. המקור האמיתי הוא אנליטי. מטרתנו היא לגזור את התוחלת של התשואה לפי פרמטרי המדיניות, $\nabla_{\theta} \mathbb{E}_{\tau \sim p_{\theta}}[R(\tau)]$. הקושי: התפלגות המסלולים $p_{\theta}(\tau)$ תלויה בעצמה ב- θ , ולכן איננו יכולים פשוט להעביר את אופרטור הגזירה אל תוך האינטגרל. כאן נעזרים בזהות הבסיסית $\nabla_{\theta} p = p \nabla_{\theta} \log p$, המוכרת כ**טריק יחס הנראות** (Likelihood-Ratio Trick):

$$\nabla_{\theta} \int p_{\theta}(\tau) R(\tau) d\tau = \int p_{\theta}(\tau) \nabla_{\theta} \log p_{\theta}(\tau) R(\tau) d\tau = \mathbb{E}_{\tau \sim p_{\theta}}[\nabla_{\theta} \log p_{\theta}(\tau) R(\tau)] \quad (3)$$

כאשר מפרקים את $\log p_{\theta}(\tau)$ למצבים ולפעולות תחת הנחת מרקוב, הגרדיאנטים של פונקציות המעבר של הסביבה – שאינן תלויות ב- θ – מתאפסים, ונשאר בדיוק סכום הלוגים של הסתברויות המדיניות מוכפל בתשואה. זוהי תוצאת **משפט גרדיאנט המדיניות** [4]. היופי בכך: מתקבל אומדן מבוסס-דגימות (sample-based estimator) לגרדיאנט **בלי לדעת דבר על מודל המעברים של העולם** – כלומר שיטה חסרת-מודל (model-free).

להעמקה: הפיתוח המלא, כולל הנחות הרגולריות הנדרשות, מופיע אצל [1] ובמאמר המקורי של [3].

2.6 הקשר ל-Cross Entropy: ה-One-Hot כ"אמת"

יש פה תובנה יפה. נניח שבמצב מסוים הרשת נתנה לי הסתברויות $[0.4, 0.6]$ בין "ימין" ל"שמאל", ובהגרלה יצא לי "שמאל". ברגע שביצעתי את הפעולה, ה"אמת" (Label) שלי היא וקטור $[1, 0]$ בקידוד One-Hot – כי זה מה שעשיתי בפועל.

לכאורה, באופן חד-פעמי, הרשת "טעתה": היא נתנה $[0.4, 0.6]$ ואני עשיתי $[1, 0]$. ההפרש בין הווקטורים האלה הוא בדיוק מה שמאפשר לי לעשות גרדיאנט ולתקן את הרשת, בדיוק כמו ב-Cross Entropy של בעיית סיווג. אבל – וזה העיקר – ההפרש הזה מוכפל בתשואה המצטברת. כך משחקים יחד שני כוחות: מצד אחד הניחוש הנקודתי, ומצד שני התוצאה הסופית של כל המסלול.

2.7 דיוק והעמקה: שקילות מתמטית ל-Cross Entropy

ההקבלה הזו אינה רק אינטואיציה – היא מקבלת תוקף מתמטי מלא, וזו אחת התובנות המעשיות החשובות ביותר למהנדסי למידת מכונה. פונקציית האנטרופיה הצולבת (Cross Entropy) בין החיזוי למצוי מוגדרת כ- $-\log p(y | x)$. בלמידת חיזוק, כאשר ה"אמת המדומה" (pseudo-label) שלנו היא הפעולה a_t שנדגמה בפועל, גזירת ההפסד מחזירה בדיוק את האיבר $-\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)$ – אותו איבר שראינו במשוואת גרדיאנט המדיניות. ההבדל היחיד: במקום ירידת גרדיאנט רגילה (Gradient Descent), אנו משקללים את שגיאת האנטרופיה הצולבת בתשואה G_t . אם המסלול הניב תגמול חיובי גבוה, נשאף למזער את האנטרופיה הצולבת ביחס לפעולות שננקטו – כלומר לדחוף את ההסתברות לאותן פעולות כלפי 1.0.

המשמעות ההנדסית עמוקה: אפשר לממש את REINFORCE בעזרת אותה פונקציית הפסד ואותו אופטימיזר של סיווג רב-מחלקתי בספריות כגון PyTorch ו-TensorFlow, ולנצל חישוב יעיל על מעבדי GPU, בלי לכתוב אופטימיזר מיוחד. כך מתחברים היסודות התיאורטיים של למידת החיזוק ישירות לעולם המעשי של הקוד [1].

3 בעיית הרעש וקו הבסיס (Baseline)

לשיטה הבסיסית שתיארנו יש בעיה רצינית. אם אני מחליף את הערך של כל צעד בודד בתוצאה הגלובלית האחרונה, אני יוצר זרימה בעייתית מבחינה מבנית.

3.1 הדגמה: צעד אחד שמקלקל את הכול

דמיינו מסלול של עשרה צעדים, שבו כל צעד תרם 10 נקודות – אבל בסוף מישהו אחד שם לנו מינוס 100, ובסך הכול חטפנו מינוס 10. במצב כזה **כולם ייענשו בגלל אחד שקלקל**. תשע הפעולות המצוינות הראשונות נפגעות מתמטית בגלל פעולה גרועה אחת בסוף.

זה מה שנקרא במונח המקצועי **רעש** (Noise). המערכת הופכת להיות מאוד לא יציבה, כי מספיק ערך אחד קיצוני כדי לקלקל. זה כמו ממוצע: בדרך כלל הוא יציב, אבל מספיק ערך חריג אחד כדי שהוא יקפוץ בצורה משוגעת. פעם המערכת מצליחה, פעם אחד מפיל אותה חזק למטה, וחוזר חלילה. המערכת רועשת.

3.2 הפתרון: החסרת הממוצע

כדי לטפל בזה אנחנו מחסירים **קו בסיס** (Baseline), שמסומן באות b . במקום לקחת את התשואה כמו שהיא, אנחנו מחסירים ממנה את הממוצע, ומסתכלים על ההפרש ביחס לבסיס:

$$(4) \quad \theta \leftarrow \theta + \alpha \sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) (G_t - b)$$

נניח שהממוצע הוא 8. אם מסלול נתן 12, ההפרש חיובי: +4. אם מסלול אחר נתן 5, ההפרש שלילי: -3, ואנחנו מורידים את הסיכוי לפעולות האלה. כך אנחנו עוברים מתוצאות אבסולוטיות לביצוע **יחסי**, ומסננים את הצליל הכאוטי.

3.3 הממוצע של מה?

מה זה הממוצע הזה? זה הממוצע של הניקוד **על פני כל המסלולים האפשריים**, לרוחב כל האפיזודות. אם בכל אפיזודה צברתי ניקוד אחר – 10, 10, 2, 8, וכן הלאה – אני סוכם את כולם ומחשב ממוצע. זה כמו להזיז את הממוצע של התפלגות נורמלית לאפס: ההתפלגות נשארת אותו דבר, אבל עכשיו אנחנו מודדים את התרומה האמיתית ולא “כל מיני דברים משוגעים” שקרו באותו רגע. חשוב להדגיש: החסרת הבסיס **לא משנה את המטרה המתמטית** – היא רק מורידה את הרעש.

3.4 דיוק והעמקה: מדוע קו הבסיס אינו מטה את האומדן

הקביעה שהחסרת קו הבסיס “לא משנה את המטרה” אינה מובנת מאליה, וסטודנט המתכנן מערכת אמיתית חייב להבין מדוע מותר להוסיף איבר חיסור שרירותי בלי לעוות את כיוון הגרדיאנט. ההוכחה קצרה ויפה. נבחן את התרומה של איבר הבסיס $b(s)$ לתוחלת הגרדיאנט. מכיוון ש- $b(s)$ אינו תלוי בפעולה a , נוכל להוציאו מחוץ לסכימה על פני הפעולות, ולהשתמש שוב בזהות $\nabla_\theta \pi = \pi \nabla_\theta \log \pi$:

$$\mathbb{E}_{a \sim \pi} [\nabla_\theta \log \pi_\theta(a | s) b(s)] = b(s) \sum_a \pi_\theta(a | s) \nabla_\theta \log \pi_\theta(a | s) = b(s) \sum_a \nabla_\theta \pi_\theta(a | s) \quad (5)$$

ומכיוון שנגזרת של סכום היא סכום הנגזרות, וסכום ההסתברויות שווה תמיד ל-1, נקבל:

$$(6) \quad = b(s) \nabla_\theta \left(\sum_a \pi_\theta(a | s) \right) = b(s) \nabla_\theta (1) = 0$$

לפיכך כל איבר בסיס התלוי במצב בלבד אינו מטה את אומדן הגרדיאנט – האומדן נשאר **חסר-הטיה** (Unbiased) – אך הוא יכול להקטין דרמטית את שונות האומדן על פני הדגימות, וכך להאיץ את ההתכנסות. בסטטיסטיקה הטכניקה הזו מוכרת כ**משנתה בקרה** (Control Variate). זהו מקרה מיוחד ומבורך: בדרך כלל הקטנת שונות באה במחיר של הטיה (Bias–Variance Trade-off), אך כאן אנו מקבלים הפחתת שונות “בחינם” מבחינת הטיה [1], [5].

4 תגמול מהמצב והלאה (Reward-to-Go), עיקרון

הסיבתיות וחוקי מרקוב

הבסיס פתר את בעיית הרעש, אבל נשארה עוד בעיה לוגית הקשורה לזמן. פעולה שנעשתה בצעד מספר 5 לא יכולה להשפיע על התגמולים שכבר שולמו בצעדים 1 עד 4. השיטה הקודמת – לאסוף את כל הניקוד מההתחלה ועד הסוף – מערבבת מידע שלא קשור.

4.1 מרקוב: לא מעניין מאיפה הגעתי

אנחנו תמיד מתחילים כל מצב "מכאן ואילך". זה בדיוק חוק מרקוב: לא חשובה ההיסטוריה, אנחנו ממשיכים מהנקודה שבה אנחנו נמצאים. במשחק שח, לא מעניין איך הגעתי למצב שעל הלוח – מה שמעניין זה איך אני ממשיך מכאן והלאה. לכן המצבים שקדמו למצב הנוכחי אינם רלוונטיים לחישוב ההסתברות שלי כאן.

4.2 סכימה הדרגתית

לכן, במקום לסכום את כל התגמולים, אני עושה **סכימה הדרגתית**: עבור כל מצב אני סוכם רק את התגמולים מאותו מצב והלאה. בכל פעם אני מסתכל קדימה בלבד. זה מה שנקרא Reward-to-Go, ובניסוח מהוון (discounted):

$$(7) \quad G_t = \sum_{t'=t}^T \gamma^{t'-t} r_{t'}$$

ההיסטוריה לא אמורה להשפיע על ההסתברות שלי כאן, לפי מרקוב. כך כל מצב מקבל תשואה "הוגנת" שמשקפת רק את מה שקרה אחריו.

4.3 דיוק והעמקה: סיבתיות מול מרקוביות

הקישור שעשינו לחוק מרקוב הוא גשר אינטואיציה מצוין, אך מבחינה אקדמית פורמלית כדאי לחדד נקודה עדינה. ההצדקה לזניחת תגמולי העבר אינה נובעת ישירות מחוק מרקוב – העוסק במעברי מצבים ובהתפלגות העתיד בהינתן ההווה – אלא מעיקרון יסודי לא פחות: **עיקרון הסיבתיות** (Causality). פעולה המתבצעת בזמן t אינה יכולה בשום אופן לשנות תגמולים שכבר התקבלו בזמן

מוקדם יותר $t' < t$. מבחינה פורמלית, תוחלת ההשפעה של הפעולה בזמן t על תגמולי העבר שווה לאפס.

לכן, הכללת תגמולי העבר בתוך התשואה הכוללת של REINFORCE אינה מטה את תוחלת העדכון – אך היא "מזהמת" את הגרדיאנט ברעש עצום הנגזר מהיסטוריה שכבר אינה רלוונטית. המעבר ל-Reward-to-Go הוא אפוא צעד נוסף של הפחתת שונות, הנשען על יחסי סיבה-ומסובב טהורים בדיוק כפי שקו הבסיס הקטין שונות בלי להטות [1], [5]. שני המנגנונים יחד – קו בסיס ותגמול-מהמצב-והלאה – מנקים את האומדן מרעש מבלי לפגוע בכיוון הלמידה.

5 שחקן ומבקר: ארכיטקטורת Actor-Critic (A2C)

עד עכשיו עבדנו עם רשת אחת. עכשיו אנחנו מגיעים לחלק השני של השיעור: רשת משופרת, שהיא בעצם שילוב של **שתי רשתות**. התוספת השלישית לשיפור השיטה נקראת **יתרון** (Advantage).

5.1 משל השחקן והמאמן

יהיו לנו שתי רשתות. רשת אחת, שתפקידה להחליט איזו פעולה לבצע – ימינה, שמאלה וכן הלאה. זה כמו **שחקן כדורגל** (Actor): הוא מחליט אם לבעוט ימינה או שמאלה ומבצע. הרשת השנייה היא **המאמן** (Critic), המבקר, שעומד מחוץ למגרש, מנתח את המצב ואומר: "תשמע, בדרך כלל במצב כזה לא בועטים ימינה".

המבקר נותן ניקוד למצב, שמשקף עד כמה טוב המצב שבו אני נמצא. ככל שהניקוד גבוה יותר, כך אני במקום טוב – לא משנה כל כך מה אעשה, יש לי סיכוי גבוה להצליח. ולהפך: ניקוד נמוך אומר שיש סיכוי גבוה להיכשל. גם המבקר הוא רשת נוירונים, שמקבלת את המצב (State) ומוציאה שיערוך $V(s)$ – עד כמה המצב הנוכחי טוב, על בסיס ניסיון העבר שאיתו אומנה.

5.2 שתי רשתות, שני מוצאים

שתי הרשתות מקבלות בכניסה את אותו מצב – וקטור של ארבעה ערכים, למשל. בדרך כלל הן רשתות Fully Connected. אבל המוצא שונה:

- **השחקן** (Actor) מוציא וקטור של הסתברויות – את המדיניות.

- **המבקר** (Critic) מוציא מספר אחד – עד כמה המצב טוב.

שתי הרשתות גם נותנות תשובה וגם מתקנות את עצמן בכל פעם.

5.3 היתרון (Advantage): הפרש בין תחזית למציאות

נניח שהגעתי למצב, והמבקר אמר לי: "המצב שלך שווה 5". אני פניתי שמאלה, ובום – קיבלתי 7 נקודות. כלומר, המצב שלי באמת שווה 7, לא 5. יש פה הפרש: התחזית הייתה 5 והמציאות 7, אז ההפרש הוא $+2$.

המשמעות: הפנייה שמאלה הייתה **חזקה יותר ממה שחשבנו** – לא רק בגלל הסכום המצטבר, אלא גם מקומית, במקרה הפרטי הזה. בדיוק זה

מה שפותר את בעיית "התרומה המקומית" שאלגוריתם REINFORCE התעלם ממנה. דוגמה נוספת מעולם המניות: הערכת השמניה תהיה מחר 7, ובמציאות היא 10 – ההפרש הוא הרווח הבלתי-צפוי.

5.4 דיוק והעמקה: הגדרת היתרון וקירוב ה-TD-

כדי להבין לעומק את "הניקוד" הזה, נישען על יסודות התכנות הדינמי המרקובי. **פונקציית היתרון** (Advantage) **הטהורה** מוגדרת כהפרש בין ערך הפעולה במצב לבין ערך המצב הכללי:

$$(8) \quad A^\pi(s_t, a_t) = Q^\pi(s_t, a_t) - V^\pi(s_t)$$

כלומר, עד כמה בחירה בפעולה a_t עולה על תוחלת הציפייה הכללית מהמצב s_t . אלא שאחזקה של שתי רשתות נפרדות – אחת ל- Q ואחת ל- V – מסורבלת חישובית. במקום זאת ננצל את **משוואת בלמן** (Bellman Equation), האומרת $Q^\pi(s_t, a_t) = \mathbb{E}[r_t + \gamma V^\pi(s_{t+1})]$. מתוך דגימות שנאספות באינטראקציה אנו מחשבים את **שגיאת ההפרש הזמני** (TD Error):

$$(9) \quad \delta_t = r_t + \gamma V_\psi(s_{t+1}) - V_\psi(s_t)$$

כאשר r_t הוא התגמול המיידי שקיבלתי אחרי הפעולה, $V_\psi(s_t)$ הוא שיערוך המצב הנוכחי, ו- $V_\psi(s_{t+1})$ הוא שיערוך המצב הבא (שניהם ניתנים בידי רשת המבקר), ו- γ הוא מקדם ההיוון. הנקודה האקדמית החשובה: δ_t **אינו** פונקציית היתרון עצמה, אלא **אומדן חסר-הטיה ומבוסס-דגימות** שלה – בתוחלת $\mathbb{E}[\delta_t] = A^\pi(s_t, a_t)$ [5]. הבחנה זו היא הבסיס לכל שיטות ה-Actor-Critic המודרניות.

5.5 שני עדכונים: האקטור והקריטיק

ה-Advantage עושה שני דברים בו-זמנית: גם מזין את האקטור, וגם חוזר לעדכן את הקריטיק עצמו.

עדכון האקטור (המדיניות): כמו ב-REINFORCE, אבל במקום התשואה המצטברת אנחנו מכפילים בהפרש δ_t :

$$(10) \quad \theta \leftarrow \theta + \alpha \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \delta_t$$

עדכון הקריטיק (פונקציית הערך): הקריטיק טעה בהערכה – הוא צפה 5 וקיבלנו 7, אז הוא צריך לחזור ולהתאמן. ההפרש δ_t הוא ה-Loss שלו, והוא מעדכן את המשקלים שלו בכיוון הגרדיאנט:

$$(11) \quad \psi \leftarrow \psi + \beta \delta_t \nabla_{\psi} V_{\psi}(s_t)$$

כאשר β הוא קצב הלמידה של הקריטיק. כך שתי הרשתות מתאמנות זו על זו בזמן אמת: האקטור לומד לקבל החלטות טובות יותר, והקריטיק לומד לתת פידבק מדויק יותר.

הערה למימוש (חשובה לתרגיל 3): משוואה 11 מציגה את העדכון כצעד גרדיאנט, אך בפועל, כשמממשים ב-PyTorch או ב-TensorFlow, מגדירים את אימון המבקר כבעיית רגרסיה ומאמנים אותו למזער את השגיאה הריבועית הממוצעת (Mean Squared Error) של שגיאת ה-TD:

$$(12) \quad L(\psi) = \frac{1}{2} \delta_t^2 = \frac{1}{2} (r_t + \gamma V_{\psi}(s_{t+1}) - V_{\psi}(s_t))^2$$

מזעור זה, בעזרת אופטימיזר סטנדרטי של ירידת גרדיאנט, מבטיח שרשת המבקר תתכנס לחיזוי מדויק של ערך משוואת בלמן [6].

5.6 דיוק והעמקה: על השם A2C

הערה טרמינולוגית למי שימשיך לספרות המחקרית: הארכיטקטורה שתיארנו היא הגרסה הגנרית של **שחקן-מבקר מבוסס יתרון** (Advantage Actor–Critic). המילה Advantage עצמה היא שמבדילה שיטה זו מגישות מבקר ישנות יותר שהסתמכו על תוחלת ה- Q בלבד. בעולם המחקר, השם A2C התקבע לרוב עבור **מימוש סינכרוני** ספציפי, שבו מספר סוכנים מתאמנים במקביל על סביבות שונות ומעדכנים משקלים משותפים בו-זמנית – וריאנט סינכרוני של משפחת A3C (Asynchronous Advantage Actor–Critic) [6]. העיבוד המקבילי הזה משפר את יציבות הלמידה, אך עקרון השחקן והמבקר שהצגנו נשאר הליבה המשותפת לכל הווריאנטים.

6 סיכום: שלושת מנגנוני השיפור

עברנו דרך התפתחות הדרגתית. מערכות למידת מכונה מורכבות לא נבנות בקפיצה אחת – בונים אותן צעד אחר צעד, מבודדים בעיה מבנית ומתקנים אותה, עד שהלוגיקה מתיישבת. הנה התמונה המלאה:

1. **תשואה מצטברת** (Total Return): התחלנו מ-REINFORCE הבסיסי, שלוקח את התשואה הסופית ומחלק את הקרדיט לכל הפעולות. הבעיה: שונות (Variance) גבוהה, רעש.
2. **קו בסיס** (Baseline): החסרנו את הממוצע כדי לבחון פעולות באופן יחסי, וכך הורדנו את הרעש בלי לשנות את המטרה המתמטית.
3. **תגמול מהמצב והלאה** (Reward-to-Go): כדי לכבד את חוקי מרקוב, כל מצב סוכם רק את התגמולים שמכאן והלאה, ולא מערבב את העבר.
4. **יתרון** (Advantage): הוספנו רשת מבקר (Critic) שחוזה כמה המצב טוב, וה-Advantage הוא ההפרש בין התגמול האמיתי לתחזית. כך הגענו לארכיטקטורת Actor-Critic המלאה.

6.1 REINFORCE מול A2C: ההבדל

נסכם את ההבדל בין שני האלגוריתמים:

- REINFORCE – רשת **אחת** בלבד. כל מה שהיא עושה זה לתקן את ההסתברויות. אין לה מבקר, היא לא מתייחסת לעד כמה המצב טוב כרגע. פשוט ובסיסי.

- A2C (Actor-Critic) – **שתי** רשתות. רשת אחת מוציאה וקטור הסתברויות (האקטור), והשנייה מוציאה מספר שמעריך את טיב המצב (הקריטיק). העדכון של האקטור נשען על הערכת הקריטיק (ה-Advantage), ולא רק על התשואה הסופית.

זהו הבסיס שעליו נשען התרגיל הבא, שבו נשתמש בשני האלגוריתמים האלה גם יחד.

6.2 טבלה מסכמת: מילון המונחים המתמטיים

הטבלה הבאה מאגדת את ההגדרות הפורמליות של המושגים המרכזיים שפיתחנו, לצד תפקידם המעשי. שליטה בסימונים אלה חיונית לקריאת ספרות מחקרית בלמידת חיזוק, שכן רובה משתמשת באותה נוטציה בינלאומית.

טבלה 1: מילון מונחים מתמטיים בלמידת מדיניות (Policy Gradient Glossary)

מונח	הגדרה מתמטית	תפקיד מעשי
מדיניות (Policy)	$\pi_\theta(a s)$	ממפה מצב לווקטור הסתברויות לפעולות; מנוהלת על ידי האקטור.
תשואה מהמצב והלאה (Reward-to-Go)	$G_t = \sum_{k=t}^T \gamma^{k-t} r_k$	פונקציית המטרה לאופטימיזציה; מתקנת את בעיית העבר לפי עיקרון הסיבתיות.
קו בסיס (Baseline)	$b(s) \approx V^\pi(s)$	משתנה בקרה המפחית שונות מבלי להטות את תוחלת הגרדיאנט.
פונקציית היתרון (Advantage)	$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$	מודד עד כמה פעולה עדיפה על תוחלת המצב הכללית.
שגיאת הפרש זמני (TD Error)	$\delta_t = r_t + \gamma V_\psi(s_{t+1}) - V_\psi(s_t)$	אומדן חסר-הטיה ומבוסס-דגימות של היתרון.

6.3 טבלה מסכמת: מפת מקורות לקריאת המשך

לטובת סטודנטים המעוניינים בהעמקה ובעבודות המשך, הטבלה הבאה ממפה כל מושג מרכזי בהרצאה אל מקור היסוד שלו בספרות. ההפניות המלאות מופיעות בפרק הביבליוגרפיה שבסוף המסמך.

טבלה 2: מפת מקורות אקדמיים לפי מושג (Reference Map)

מושג בהרצאה	עיגון ספרותי	משמעות לשילוב
מסגרת MDP ולמידת חיזוק	[1]	ספר היסוד של התחום; ההגדרות הפורמליות לפרקים 1 ו-5.
משפט גרדיאנט המדיניות	[3], [4]	הבסיס לטריק נגזרת הלוג; מחליף את ההסבר הנומרי בפרק 2.
קו בסיס והפחתת שונות	[5]	הצדקה לאומדן היתרון ולמשתני בקרה.
Actor-Critic ו-A2C	[6]	מקור השם A2C והווריאנט הסינכרוני.
LSTM כמייצג סביבה	[7]	מודל עולם עבור תרגיל 3; Model-Based RL.
מיסוך פעולות (Action Masking)	[8]	שילוב ידע מומחה ואילוצי בטיחות בתוך המדיניות.

7 תרגיל מספר 3: LSTM, REINFORCE ו-A2C-

להמלצת אימונים

בתרגיל הזה אתם תבנו צינור (Pipeline) מפושט של למידת חיזוק להמלצת אימוני כושר, תוך שימוש במסד נתונים אמיתי שתורידו מ-Kaggle. המטרה היא לחבר שלושה רעיונות לכדי צינור אחד קוהרנטי:

1. להשתמש בנתוני אימון היסטוריים כדי לבנות מצבים יומיים של מתאמן.
2. לאמן רשת LSTM שתקרב את האופן שבו מצב המתאמן מתפתח לאורך זמן.

3. להשתמש במודל המעברים הנלמד הזה כסביבה (Environment) עבור שיטות גרדיאנט המדיניות, שימליצו על האימונים הבאים.

הערה חשובה לגבי הציון: בכדי לחסוך בטוקנים, ניתן לעבוד עם בסיס נתונים קטן יותר, ובלבד שעקרון האימון והתוצאה יראו הבנה של הנושא. הציון אינו ניתן על מידת איכות אימון המודל, אלא מתייחס לאופן מימוש הפרויקט, להבנת הנושא וליכולת הניתוח וההסבר.

התרגיל בנוי מששה חלקים: (A) ניסוח הבעיה, (B) הורדת הנתונים והכנתם, (C) מימוש מודל LSTM, (D) מימוש REINFORCE, (E) מימוש A2C, ו-(F) ניתוח ודיון.

7.1 חלק A – ניסוח הבעיה

המטרה היא למדל את תכנון האימונים כבעיית קבלת החלטות סדרתית. בכל יום או מפגש אימון, הסוכן בוחר את סוג האימון הבא עבור המתאמן. המטרה ארוכת-הטווח היא לשפר את איכות האימון, תוך הימנעות מעומס יתר (Over-load) ומחוסר איזון. עליכם לנסח את הבעיה כתהליך החלטה מרקובי (MDP), או כתהליך מרקובי בקירוב.

7.1.1 הרכיבים שעליכם להגדיר

- מצב s_t – ייצוג קומפקטי של מצב המתאמן בזמן האחרון.
- פעולה a_t – סוג האימון שמוקצה בזמן t .
- תגמול r_t – ערך משוב סקלרי, שמשקף האם האימון שנבחר היה מועיל.
- מעבר $P(s_{t+1} | s_t, a_t)$ – לא ידוע במציאות, ויקורב בהמשך באמצעות ה-LSTM.

האינטואיציה: מצב המתאמן בזמן t אינו מוגדר רק על-ידי האימון הנוכחי. הוא תלוי בהיסטוריה של המפגשים הקודמים, בעייפות המצטברת, ובאופן שבו נפח האימון התחלק בין קבוצות השרירים. בדיוק בגלל זה אנחנו משתמשים במודל סדרתי: מעבר המצב תלוי-היסטוריה, וה-LSTM הוא דרך טבעית למדל תלות זמנית כזו.

7.1.2 תוצרי חלק A

הגדרה מדויקת בכתב של המצב, הפעולה והתגמול; הסבר קצר מדוע המלצת אימונים היא באופן טבעי בעיית החלטה סדרתית; ותרשים או סקיצת פסאודו-קוד של צינור הלמידה.

7.2 חלק B – מסד הנתונים להורדה

בתרגיל זה תעבדו עם מסד נתוני אימונים אמיתי מ-Kaggle, המכיל הן רשומות מפורטות ברמת התרגיל והן סיכומים ברמת התוכנית.

- שם: 600K+ Fitness Exercise & Workout Program Dataset.

- מחבר: Adnane Louardi.

- עמוד מסד הנתונים:

<https://www.kaggle.com/datasets/adnelouardi/600k-fitness-exercise-and-workout-program-dataset>

- קבצים:

program_summary.csv,

programs_detailed_boostcamp_kaggle.csv

לפי כרטיס מסד הנתונים, הוא מכיל 605033 רשומות תרגיל בודדות בקובץ המפורט, ו-2598 תוכניות כושר ייחודיות בקובץ הסיכום.

7.2.1 מדוע מסד הנתונים הזה מתאים

מסד הנתונים מספק שתי רמות עבודה: **נתונים מפורטים** ברמת התרגיל (שם התרגיל, סטים, חזרות, עצימות, שבוע, יום וזמן), וכן **מטא-נתונים** ברמת התוכנית (כותרת, תיאור, רמה, מטרה, ציוד, אורך התוכנית, זמן לאימון וסך התרגילים). כך אפשר להשתמש בשורות המפורטות כדי לבנות רצפים ברמת היום, ובקובץ הסיכום כדי לבחור תוכנית אימונים קוהרנטית שתגדיר מסלול של מתאמן סינתטי אחד.

7.2.2 הוראות הורדה ישירה

עליכם להחזיק חשבון Kaggle ולהיות מחוברים לפני ההורדה. **אפשרות 1 – דרך הדפדפן:** פתחו את עמוד מסד הנתונים, לחצו על כפתור ה-Download, שמרו וחלצו את קובץ ה-ZIP, וודאו ששתי קבצי ה-CSV קיימים. **אפשרות 2 – דרך ה-Kaggle API:**

הורדה דרך Kaggle API

```
kaggle datasets download -d adnanelouardi/600k-fitness-  
exercise-and-workout-program-dataset  
unzip 600k-fitness-exercise-and-workout-program-dataset.zip
```

7.2.3 תוכן הקבצים

הקובץ program_summary.csv – שורה אחת לכל תוכנית אימון, עם תיאור ברמה גבוהה. שדות צפויים: title, description, level, goal, equipment, program_length (משך בשבועות), time_per_workout, total_exercises, ו-created/last_edit.

הקובץ programs_detailed_boostcamp_kaggle.csv – רשומות ברמת התרגיל. שדות צפויים: כותרת ותיאור התוכנית, מזהי שבוע ויום, שם התרגיל, סטים וחזרות, עצימות, רמת כושר, מטרה, ציוד וזמן לאימון.

שימו לב: כרטיס מסד הנתונים מציין במפורש כי **ערכים שליליים** בשדות sets או reps עשויים לייצג **זמן בשניות**. לכן עליכם לבדוק את המקרים האלה בקפידה בשלב העיבוד המקדים.

7.2.4 בניית מתאמן סינתטי אחד

עליכם לבנות את הצינור סביב מתאמן סינתטי אחד, הנגזר מתוכנית אימון אחת שנבחרה.

1. **בחירת תוכנית:** פתחו את `program_summary.csv` ובחרו תוכנית רב-שבועית ריאליסטית – למשל תוכנית כוח או היפרטרופיה. סננו לפי קריטריונים כמו `equipment = Full Gym` ו-`program_length` של 8 שבועות ומעלה, ו-`time_per_workout` בין 45 ל-120 דקות. רשמו את המזהה כ-`chosen_program`.
2. **חילוץ השורות המפורטות:** פתחו את הקובץ המפורט ושמרו רק את השורות השייכות ל-`chosen_program`.
3. **בניית מפגשים יומיים:** קבצו את השורות לפי `week` ו-`day`. עבור כל יום t חשבו לפחות את התכונות הבאות:

$$(13) \quad \text{total_volume}_t = \sum_i (\text{sets}_i \cdot \text{reps}_i)$$

וכן `muscle_distribution_t` (נפח מנורמל לכל קבוצת שריר), `session_duration_t`, `week_index_t` ו-`day_in_cycle_t`. אם לצירוף שבוע-יום אין אימון, הוסיפו **יום מנוחה** (Rest Day) עם נפח אפס.

יצירת מסלול המתאמן: "שטחו" את התוכנית לרצף מסודר אחד של ימים, $(s_1, s_2, \dots, s_T)$, כאשר כל איבר מתאים ליום אחד. הרצף הזה הוא המסלול (Trajectory) של המתאמן הסינתטי, ועליו נשען כל מה שבא בהמשך.

7.3 חלק C – מימוש מודל LSTM

מסד הנתונים סדרתי ברמת התוכנית: מה שצריך לקרות ביום $t + 1$ תלוי במה שקרה בימים הקודמים. יום בודד עדיין אינו מספיק כדי לאפיין את מצב המתאמן – ההשפעה של האימון היום תלויה בעומס האחרון, באיזון בין קבוצות השרירים, ובשאלה אם הימים הקודמים היו עצימים או של מנוחה. לכן ה-LSTM משמש ללמידת **מודל מעברים** (Transition Model) שלוכד תלות זמנית:

$$(14) \quad s_{t+1} \approx f_\phi(s_t, a_t, h_t)$$

כאשר s_t הוא המצב הנוכחי, a_t הפעולה שנבחרה, h_t הייצוג החבוי שה-LSTM לומד, ו- f_ϕ חוזה את המצב הבא.

7.3.1 המימוש הנדרש

1. הגדירו וקטור מצב s_t , למשל: עומס מתגלגל של 7 ימים, ציון איזון בין קבוצות שרירים, ממוצע משך מפגש, ומדד שבוע או יום-במחזור.
2. הגדירו מרחב פעולות a_t : המירו את האימונים היומיים למספר קטן של סוגי אימון – למשל קבצו את המפגשים ל-4 עד 8 קטגוריות לפי נפח, דגש שרירי ומשך. כל אשכול הופך לפעולה בדידה אחת.
3. בנו מודל LSTM שמקבל רצף של מצבים ופעולות אחרונים, וחוזה את המצב הבא.
4. אמנו את ה-LSTM בלמידה מונחית (Supervised) על חלונות רצופים מתוך מסלול המתאמן.

הערה חשובה: למרות שמסד הנתונים מכיל תוכניות ולא מדידות פיזיולוגיות, הוא עדיין שימושי כי הוא מספק **דפוסי אימון זמניים מובנים** שניתן להמיר למעברי מצב. ה-LSTM אינו הממליץ הסופי, אלא קירוב נלמד של סביבת האימון. תוצרי חלק C: הגדרת s_t ו- a_t , תיאור ארכיטקטורת ה-LSTM, עקומות Loss לאימון ולוולידציה, ודיון אם המודל לוכד דפוסים זמניים בעלי משמעות.

7.3.2 הקשר תיאורטי: מודל עולם (World Model)

חשוב שתכירו את השם התיאורטי המדויק למה שאתם בונים כאן. כאשר רשת זיכרון (LSTM) נלמדת מתוך נתונים היסטוריים כדי לשמש **מייצרת סביבה** (Environment) שבתוכה הסוכן מתאמן, התהליך מכונה בנייה של **מודל עולם** (World Model) – מושג שהתקבע אקדמית בעקבות עבודתם של דייוויד הא ויורגן שמידהובר [7], והוא לב התחום של Model-Based RL. רשת הזיכרון מאפשרת לבנות פונקציית מעברים התלויה במצב החבוי h_t , ובכך היא הופכת בעיה של תצפית חלקית, שבה חוק מרקוב נפגע (POMDP), חזרה לבעיית קבלת החלטות מרקובית שניתן לפתור. הכירו את המונח World Model – כך תפגשו אותו בכנסים ובמאמרים בהמשך דרככם.

7.4 חלק D – מימוש REINFORCE מעל מודל ה-LSTM

המטרה: להשתמש במודל המעברים המאומן כסביבה, ולאמן מדיניות באמצעות REINFORCE כדי לבחור פעולות אימון לאורך זמן. המדיניות תפעל על רצף המצבים הסינטיים שבניתם, ולא ישירות על שורות ה-CSV הגולמיות.

7.4.1 ניסוח המדיניות

תהי המדיניות $\pi_\theta(a_t | s_t)$, כאשר הפעולה היא סוג האימון הבא. המדיניות מיוצגת על-ידי רשת נוירונים שמקבלת את המצב הנוכחי ומוציאה התפלגות קטגוריאלית מעל סוגי האימונים. תייצרו אפיזודות באורך קבוע (למשל 28 ימים), ובכל צעד: צופים את s_t , דוגמים פעולה $a_t \sim \pi_\theta(a_t | s_t)$, משתמשים ב-LSTM כדי לחזות את s_{t+1} , מחשבים תגמול r_t , וממשיכים עד סוף האפיזודה.

7.4.2 עיצוב התגמול

הגדירו תגמול שמעודד אימון פורה אך מאוזן, למשל:

$$(15) \quad r_t = \text{gain}_t - \lambda_1 \cdot \text{overload_penalty}_t - \lambda_2 \cdot \text{imbalance_penalty}_t$$

כאשר gain_t מתגמל נפח אימון מועיל, $\text{overload_penalty}_t$ מעניש עומס מתגלגל מופרז, ו- $\text{imbalance_penalty}_t$ מעניש חלוקה לא-מאוזנת בין קבוצות השרירים.

7.4.3 עדכון REINFORCE

אמנו את המדיניות לפי כלל גרדיאנט המדיניות האפיזודי (ראו משוואה 2 בפרק התיאורטי):

$$(16) \quad \theta \leftarrow \theta + \alpha \sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) G_t$$

כאשר G_t היא התשואה מזמן t . תוצרי חלק D: תיאור רשת המדיניות, תהליך יצירת האפיזודות, הגדרת התגמול והנמקתו, עקומות אימון של התשואה האפיזודית הממוצעת, גרף אבחון נוסף (כמו שונות התגמול או העומס השבועי הממוצע), ודיון בחוסר היציבות (Variance) שנצפה ב-REINFORCE.

7.5 חלק E – מימוש A2C מעל מודל ה-LSTM

ממשו Advantage Actor–Critic (A2C) על אותה סביבה מדומה מחלק D. המוטיבציה: להשוות שיטת גרדיאנט מדיניות טהורה (מונטה-קרלו) לשיטת שחקן-מבקר בעלת שונות נמוכה יותר.

7.5.1 מבנה המודל

ל-A2C שני רכיבים נלמדים: **שחקן** (Actor) – המדיניות $\pi_\theta(a_t | s_t)$; ו**מבקר** (Critic) – אומדן ערך $V_\psi(s_t)$. השחקן בוחר פעולות אימון, והמבקר מעריך עד כמה טוב מצב המתאמן הנוכחי תחת המדיניות הנוכחית. אומדן היתרון:

$$(17) \quad A_t = r_t + \gamma V_\psi(s_{t+1}) - V_\psi(s_t)$$

לאחר מכן בצעו אופטימיזציה: את **השחקן** בעזרת גרדיאנט המדיניות המשוקלל ב- A_t , ואת **המבקר** בעזרת Loss של ערך, כמו ריבוע שגיאת ה-TD. תוצרי חלק E: תיאור רשתות השחקן והמבקר, היעד המדויק שבו השתמשתם, עקומות אימון של התגמול הממוצע, והשוואה בין A2C ל-REINFORCE מבחינת יציבות ויעילות-דגימה.

7.6 חלק F – ניתוח ודיון

בחלק האחרון הרהרו על הצינור כולו ודונו במשמעות התוצאות. עליכם להתייחס לשאלות הבאות:

1. האם נראה שה-LSTM לומד מבנה זמני ריאליסטי מהתוכנית שנבחרה?
2. האם המדיניות לומדת המלצות אימון מאוזנות, או שהיא "קורסת" לחזרה על מספר קטן של פעולות?
3. האם A2C יציב יותר מ-REINFORCE בהקשר הזה?
4. מהן המגבלות העיקריות של שימוש בנתוני תוכניות אימון, במקום נתוני תוצאה אמיתיים של משתמשים?
5. כיצד אפשר היה לשפר את המערכת אילו היו זמינות מדידות של דופק, כאבי שרירים, התאוששות או התקדמות בכוח?

7.6.1 נקודות לדיון ותוצרים

עליכם להכיר בכך שזוהי **הגדרת המלצה מפושטת**, ולא סימולטור פיזיולוגי מלא. מסד הנתונים מספק רצפי אימון מובנים ומטא-נתונים שימושיים, אך אינו מודד ישירות תוצאות כמו גדילת שריר, עייפות, סיכון לפציעה או מצב התאוששות. לכן עיצוב התגמול ובניית המצב הם בחלקם היוריסטיים – ואת המגבלה הזו יש לדון בבירור.

שילוב ידע מומחה – מיסוך פעולות (Action Masking): סוכן הלומד במנותק מאילוצי העולם האמיתי עלול להציע פעולות לא סבירות או מסוכנות (למשל, העמסת משקל רב מדי שעלולה לגרום לפציעה). פתרון מקובל למעבר מתיאוריה לפרקטיקה הוא הזרקת ידע אנושי-מומחה ישירות אל מנגנון הלמידה, לרוב באמצעות טכניקת **מיסוך פעולות (Action Masking)**. הטכניקה מאפסת בהסתברות קשיחה כל בחירה שאינה עומדת בהגדרות הבטיחות – מבחינה מעשית, קובעים את הלוג של אותן פעולות ל- $-\infty$ עוד בתוך חישוב וקטור המדיניות – תוך שימור גמישות הלמידה במרחב הפעולות המותרות בלבד [8]. כך משולבים "מעקות בטיחות" (Guardrails) אנושיים לצד האופטימיזציה הלומדת. אם תרצו, תוכלו להציע בדיון כיצד מיסוך כזה היה משתלב בתוכנית האימונים שלכם.

תוצרי חלק F: טבלת השוואה בין REINFORCE ל-A2C, דיון ביקורתי קצר במגבלות מסד הנתונים, והצעה קצרה להרחבת הפרויקט עם נתונים עשירים יותר.

7.7 רשימת הגשה

ההגשה שלכם תכלול: קוד לטעינת הנתונים ולעיבוד המקדים; שיטה מתועדת לבחירת תוכנית אחת מ-Kaggle; מסלול מתאמן סינתטי ברמת היום; מימוש ה-LSTM ועקומות ה-Loss; מימוש REINFORCE עם גרפי אימון; מימוש A2C עם גרפי אימון; וסעיף דיון מסכם.

מסד הנתונים לשימוש בחלק B:

<https://www.kaggle.com/datasets/adnelouardi/600k-fitness-exercise-and-workout-program-dataset>

קבצים עיקריים:

program_summary.csv,

programs_detailed_boostcamp_kaggle.csv

8 מקורות וביבליוגרפיה (References)

רשימת המקורות הבאה מאגדת את עבודות היסוד שעליהן נשען החומר התיאורטי בסיכום זה. ההפניות בגוף הטקסט (בסוגריים מרובעים) מובילות לערכים שלהלן, וממוקמות במתכונת IEEE. הקוראים מוזמנים לפנות למקורות אלה לצורך העמקה והרחבה מעבר לחומר הנדון בכיתה.

- 1 R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. Cambridge, MA: MIT Press, 2018.
- 2 L. P. Kaelbling, M. L. Littman, and A. R. Cassandra, "Planning and acting in partially observable stochastic domains," *Artificial Intelligence*, vol. 101, no. 1–2, 99–134, 1998.
- 3 R. J. Williams, "Simple statistical gradient-following algorithms for connectionist reinforcement learning," *Machine Learning*, vol. 8, no. 3–4, 229–256, 1992.
- 4 R. S. Sutton, D. McAllester, S. Singh, and Y. Mansour, "Policy gradient methods for reinforcement learning with function approximation," in *Advances in Neural Information Processing Systems (NeurIPS)*, 12, 1999, 1057–1063.
- 5 J. Schulman, P. Moritz, S. Levine, M. Jordan, and P. Abbeel, "High-dimensional continuous control using generalized advantage estimation," in *International Conference on Learning Representations (ICLR)*, 2016.
- 6 V. Mnih et al., "Asynchronous methods for deep reinforcement learning," in *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, 2016, 1928–1937.
- 7 D. Ha and J. Schmidhuber, "Recurrent world models facilitate policy evolution," in *Advances in Neural Information Processing Systems (NeurIPS)*, 31, 2018.
- 8 S. Huang and S. Ontañón, "A closer look at invalid action masking in policy gradient algorithms," in *Proceedings of the 35th International Florida Artificial Intelligence Research Society Conference (FLAIRS)*, 2022.